

Gulich



unc



Educación a distancia

MÓDULO 3

Análisis de datos espaciales y sus aplicaciones

Unidad 3: Geoestadística

Práctico 3: Variación espacial y predicción de la acidificación del suelo

Autoría: Mariela Aguilera Sammaritano

Adaptación 2025: Antonella Galetto

Índice

Variación espacial y predicción de la acidificación del suelo

1. Introducción	2
2. Caso de estudio	2
3. Nuevo Proyecto y Rscript	3
4. Lectura de base de datos	4
5. Conversión de base de datos a objeto espacial	4
6. Variograma experimental	4
7. Variograma teórico	5
7.1 Ajuste manual de parámetros inicializadores	5
7.2 Ajuste final del variograma	6
8. Predicción espacial	7
9. Exportación de visualizaciones a GIS	9
10. Conclusiones	11
11. Bibliografía	11
¿Cómo citar este material?	12

Variación espacial y predicción de la acidificación del suelo

1. Introducción

¡Bienvenidos a la última actividad práctica! En esta instancia, aplicaremos los conocimientos de la geoestadística para analizar la variación espacial y predecir la acidificación del suelo de un sitio de estudio que veremos a continuación. Esta práctica, a diferencia de las anteriores, te desafiará a trabajar con mayor autonomía, utilizando los scripts del tutorial como guía, pero adaptándolos al caso de estudio actual. El objetivo es que ganes confianza y te prepares de la mejor manera para el trabajo práctico integrador.

Para esta unidad, nuestros objetivos principales son:

- **Estimar** parámetros geoestadísticos y obtener el gráfico de variograma experimental.
- **Ajustar** modelos de autocorrelación espacial a partir de un variograma empírico.
- **Obtener** predicciones (kriging) para los valores espaciales a partir del modelo ajustado.

A medida que avances en la guía, te recomendamos tomar nota de los resultados y capturas de pantalla de los procedimientos. Este material será fundamental para completar la evaluación práctica en el Aula virtual y participar activamente en los encuentros sincrónicos. ¡Mucho éxito!

2. Caso de estudio

Los suelos de América Latina tienen un porcentaje elevado de acidez (el 81%), lo que limita su capacidad productiva, porque disminuye la disponibilidad de nutrientes básicos, altera las comunidades microbianas y genera estructuras inestables, entre otras consecuencias (Azcarate *et al.*, 2012). La acidez se origina naturalmente por el aporte de ácidos provenientes de actividades industriales o agrícolas (Vázquez y Pagani, 2015). Centrándonos en nuestro país (Figura 1), les presentamos el caso de estudio que analizaremos en conjunto.



Figura 1: introducción al caso de estudio "Acidificación de suelos".

Para evaluar la remediación de suelos ácidos con la metodología de encalado, se tomaron muestras de suelo durante un año en una provincia de Argentina y se registraron sus valores de pH para evaluar su tendencia espacial. La tabla a utilizar se denomina "suelo" y es la misma utilizada en el tutorial de la Unidad 3. Esta vez, en lugar de trabajar con la variable "Cobre" como lo hicimos en el tutorial, lo haremos con la variable "pH".

3. Nuevo Proyecto y R Script

Comenzaremos nuestro trabajo creando un nuevo proyecto y archivo R Script. Para ello, tendrán que seguir paso a paso la secuencia de trabajo descrita en tutoriales y prácticos previos, tomando todas las precauciones allí citadas. Resumidamente:

- A. **Crear un nuevo proyecto:** Abrir un nuevo proyecto desde File > New project... y asignarle un nombre relevante a esta práctica.
- B. **Crear un R Script:** Crear un nuevo archivo R Script (File > New File > R Script) y guardarlo dentro de la misma carpeta del proyecto.
- C. **Instalar paquetes:** Usar el comando `install.packages()` para instalar los paquetes necesarios para la práctica, que serán los mismos instalados para la actividad tutorial de esta unidad. Recuerden que esto solo se hace una vez.
- D. **Cargar paquetes:** A medida que se avance en el trabajo, recuerden que deberán ir cargando los paquetes en la sesión de R para poder utilizar sus funciones, haciendo uso de la función `library()`.
- E. **Verificar la configuración:** Recuerden asegurarse de que tanto el proyecto .Rproj como el archivo .R se encuentren en la misma carpeta y sean visibles en la interfaz de RStudio.

4. Lectura de base de datos

En esta práctica, trabajarás con el archivo de datos [suelo.xlsx](#), que contiene mediciones de pH de muestras de suelo de una provincia de Argentina. El objetivo es que sigas los pasos ya conocidos para importar y preparar estos datos en tu entorno de trabajo.

- **Descargar del Aula Virtual la base de datos** suelo.xlsx y guardarla en la misma carpeta del proyecto. Sugerimos no cambiar el nombre del archivo original.
- **Importar la base de datos** desde el menú de RStudio: Environment > Import datasets > From Excel > Browse.
- **Visualizar y configurar las variables** en la ventana de importación, asegurándote de que cada columna tenga el tipo de dato adecuado antes de hacer clic en Import.
- También puedes importar la tabla de datos directamente a través del editor de scripts, tal como se explicó en tutoriales previos.

5. Conversión de base de datos a objeto espacial

Una vez leída la base de datos, procedemos a preparar nuestros datos y evaluar su calidad. Para ello, llamamos la librería necesaria ([geor](#)), convertimos la base de datos en un objeto espacial usando la función [as.geodata\(\)](#) y le asignamos un nuevo nombre. Finalmente, verificamos que no existan coordenadas duplicadas con la función [dup.coords\(\)](#). Por último, hacemos un cálculo de estadística descriptiva del objeto espacial usando la función [summary\(\)](#).



Observemos los resultados obtenidos, investiguemos:

- Viendo las coordenadas máximas y mínimas del nuevo objeto espacial, ¿de qué provincia o ciudad provienen nuestros registros?
- ¿Cuántos registros contiene la base de datos?

Importante: avanzaremos de aquí en adelante sabiendo que nuestros datos cumplen con el supuesto de normalidad, con el objetivo de enfocar nuestra práctica en la variografía experimental y teórica, y el abordaje del método de predicción kriging.

6. Variograma experimental

Una vez creado el objeto `geodata`, es decir lo que creamos arriba como base de datos espacial, procedemos a elaborar el variograma experimental haciendo uso de la función `variog` contenida en el paquete `geoR` ya instalado y cargado, asignándole un nombre al variograma. Luego, usamos la función `plot()` para graficarlo. Recuerden seguir la secuencia planteada en el tutorial, con el cuidado de adaptar el nombre de nuestra nueva base de datos creada.



En este momento les proponemos las siguientes actividades:

- Comenten las características o estructura de la distribución espacial de los datos que se pueden ver en este variograma.
- Teniendo en cuenta que: “Mientras más regular el variograma en el origen (distancias cercanas a 0), más regular es la variable regionalizada en el espacio”, ¿Cuáles son las afirmaciones que se pueden realizar sobre el variograma obtenido?
- ¿En qué valor y a qué distancia ya no existe correlación espacial para los valores de pH?

Ayuda: el valor está dado por la meseta y la distancia por el rango.

- ¿En qué provincia de Argentina se realizaron estas mediciones?

Ayuda: pueden practicar proyectar los puntos en *openstreetmap*.

7. Variograma teórico

7.1 Ajuste manual de parámetros inicializadores

Ahora, vamos a usar el variograma experimental para obtener los parámetros iniciales del modelo de autocorrelación espacial. Para ello, usaremos la misma función interactiva `window()` y `eyefit()` usada en el tutorial.

Secuencia de trabajo:

1. **Ejecutar las funciones** `window()` y `eyefit()` para abrir una ventana interactiva.
2. **Ajustar los parámetros** del modelo manualmente en esta ventana.
3. **Buscar el mejor ajuste** moviendo los parámetros hasta que la curva pase lo más cerca posible de la mayoría de los puntos del variograma experimental.

Recuerden que, el objetivo es lograr que la curva represente de la mejor manera la variabilidad espacial de los datos.

Sugerimos en esta instancia, usar como guía los siguientes parámetros inicializadores junto con una función de tipo “Wave”. Recuerden tomar nota y guardar los parámetros introducidos.

- max dist: 2.53
- sill: 1.1
- range: 0.09
- nugget: 3.8

A continuación, les invitamos a graficar nuevamente el variograma experimental con la función `plot()`, junto con la curva del variograma teórico estimado manualmente usando la función `lines.variomodel()`, y tomando la precaución de introducir el nuevo nombre del variograma y los parámetros inicializadores previamente definidos.



Tras probar distintos parámetros:

- ¿Creen que los parámetros sugeridos y la función de tipo Gaussiana son los que mejor se adaptan a los datos?

7.2 Ajuste final del variograma

En esta sección aplicaremos los métodos de ajuste automáticos ya vistos en el apartado teórico y tutorial, para refinar el ajuste manual aplicado anteriormente. Para obtener este ajuste utilizaremos la función `likfit()` y sus dos tipos de métodos de estimación ML y REML. Finalmente, les invitamos a compararlos de manera analítica (AIC) usando la función `summary()`, y gráfica usando las funciones `plot()` y `lines()`. Finalmente, les desafiamos a definir cuál de los dos modelos se ajusta mejor a los datos. Recuerden en este paso introducir en los parámetros inicializadores ya definidos manualmente.



De acuerdo a los resultados:

- ¿Qué criterio usarías para decidir qué ajuste es mejor? ¿El criterio gráfico o el analítico?
- ¿Qué valores de AIC te arrojó la función `summary()` para cada modelo, y cuál consideras que es mejor? ¿por qué?
- ¿Qué modelo implementarías para abordar la estimación de predicciones? ¿por qué?

8. Predicción espacial

Como vimos en el apartado teórico y tutorial, uno de los principales objetivos de la geoestadística es predecir valores en lugares donde no se tomaron muestras. El kriging es el método que nos permite lograrlo, creando una grilla de predicción para estimar los valores en esos puntos. A continuación, te compartimos la secuencia de trabajo resumida para llevar a adelante cada paso de este proceso. Recuerden revisar el tutorial para mayores detalles.

A. Crear la grilla de predicción

Antes de predecir, necesitamos definir el área sobre la que trabajaremos. Este paso consiste en crear una grilla de puntos que cubra toda el área de estudio, basándonos en las coordenadas de los datos existentes.

- Usar `summary()` en el objeto de datos espaciales (`suelo1` ó nombre que le hayas asignado al objeto) para obtener las coordenadas mínimas y máximas.
- Utilizar las funciones `expand.grid()` y `seq()` para crear una grilla de puntos (`pred_grid`) que cubra el área de estudio.
- Verificar la grilla con un gráfico usando `plot()` para ver los puntos de muestreo y los puntos de la grilla.

B. Realizar el Kriging

Una vez que tenemos la grilla, aplicamos el método de kriging. Este proceso utiliza el modelo de autocorrelación espacial más robusto que ajustamos y seleccionamos previamente para estimar los valores en cada punto de la grilla.

- Usar la función `krige.conv()` para predecir los valores de la variable en la grilla.
- Pasar el objeto de datos, la grilla de predicción (`pred_grid`) y el modelo de variograma ajustado (`vario.reml` ó `vario.reml`, según cuál hayas seleccionado como el más robusto) como argumentos.

C. Analizar las predicciones

En este paso exploramos la distribución de los valores predichos y la varianza asociada a cada predicción.

- Usar `summary()` e `hist()` en el resultado del Kriging (`ko.reml` ó `ko.ml`) para obtener un resumen estadístico y visualizar la distribución de los valores predichos y las varianzas.

D. Visualizar las predicciones

En este paso, convertimos los datos predichos en un formato espacial y los representamos visualmente para identificar patrones y tendencias.

- Cargar la librería `sp`.
- Convertir los datos de muestreo (`suelo`) en un objeto espacial (asignándole un nuevo nombre, por ejemplo `suelo_sp`) usando la función `coordinates()`.
- Crear un `SpatialPixelsDataFrame` a partir de los resultados del Kriging (`ko.reml` ó `ko.ml`) para la visualización.
- Usar la función `spplot()` para crear mapas de la superficie de predicción. Recuerden que se pueden agregar líneas de contorno y los puntos de muestreo originales para una mejor interpretación.

E. Visualizar la incertidumbre (mapa de varianzas)

Como vimos en el apartado teórico, no solo es importante saber la predicción, sino también cuán confiable es. En este último paso crearemos el mapa de varianzas que permitirá ver dónde la incertidumbre es mayor o menor, lo cual es clave para entender la calidad del modelo final. Para ello:

- Crear un nuevo `SpatialPixelsDataFrame` usando los valores de varianza (`ko.reml$krige.var` ó `ko.ml$krige.var`) del resultado del Kriging.
- Generar otro mapa con `spplot()` para visualizar la distribución de la varianza kriging, lo cual ayudará a identificar las zonas de mayor incertidumbre.



Analizando las salidas gráficas, nos surgen las siguientes inquietudes. Les proponemos reflexionar en conjunto:

- ¿En qué sistema de referencia se debe obtener la grilla de predicción?
- ¿En qué coordenadas la varianzas son mayores? ¿En qué sectores las predicciones son más confiables? ¿Qué se podría hacer para mejorar esto en futuros muestreos?
- ¿En qué coordenadas consideran que los valores de pH son independientes de la contaminación estudiada?
- ¿Cuál es el valor de pH predicho en la coordenada -55 ; -25?

9. Exportación de visualizaciones a GIS

En esta sección exportamos los resultados del análisis geoestadístico, como el área de estudio, puntos de muestreo, contornos y superficies de predicción y varianza, a formatos compatibles con Sistemas de Información Geográfica (GIS) como shapefiles y GeoTIFFs, para luego importarlos desde QGIS. Recuerden en esta sección aplicar el mismo CRS usado en el tutorial.

A. Exportar el área de estudio a shapefile

En este paso creamos el polígono que delimita el área de estudio. Para ello:

- Usar las funciones `min()` y `max()` para obtener las coordenadas extremas de la grilla de predicción.
- Definir los vértices del polígono con esas coordenadas.
- Crear un objeto `sf` (simple feature) para el polígono.
- Usar la función `st_write()` para exportar el polígono como un archivo `.shp` (shapefile).

B. Exportar los puntos de muestreo a shapefile

Aquí exportamos la ubicación de los puntos de muestreo de pH, junto con los datos asociados, siguiendo los siguientes pasos:

- Usar la función `st_as_sf()` para convertir el objeto de puntos de muestreo (`suelo_sp`) a un objeto `sf`.
- Usar la función `st_write()` para exportar este objeto como un archivo `.shp`.

C. Exportar los contornos de predicción a shapefile

Recordemos que los contornos de predicción son líneas que conectan puntos con el mismo valor predicho, y exportarlos permite ver las tendencias espaciales en un entorno GIS. Para lograrlo, usamos un bucle `for` para procesar cada línea de contorno individualmente. En resumen:

- Utilizar `contourLines()` para generar las líneas de contorno a partir de la matriz de predicciones.
- Usar un bucle `for` para convertir cada una de esas líneas en un objeto `sf`.
- Usar la función `st_write()` para guardar el resultado como un archivo `.shp`.

D. Exportar la superficie de predicción a ráster

En este paso, convertimos la superficie de predicción de pH en un formato de imagen espacial ([GeoTIFF](#)), ideal para una visualización continua y un análisis posterior.

- Usar la función `raster()` para convertir el `SpatialPixelsDataFrame` de las predicciones (nombre que le hayas asignado al objeto, ej. `ko.reml_sp` ó `ko.ml_sp`) en un objeto de tipo `raster`.
- Asignar el Sistema de Coordenadas de Referencia (CRS) al objeto `raster`.
- Usar la función `writeRaster()` para exportar el archivo `.tif`.

E. Exportar la superficie de varianzas a ráster

Similar al paso anterior, exportamos el mapa de varianzas para visualizar la incertidumbre de las predicciones en QGIS y determinar dónde podríamos necesitar más datos.

- Usar la función `raster()` para convertir el `SpatialPixelsDataFrame` de varianzas (nombre que le hayas asignado al objeto, ej. `ko.reml_var_sp` ó `ko.ml_var_sp`) en un objeto `raster`.
- Asignar el CRS al objeto `raster` de varianzas.
- Usar la función `writeRaster()` para exportar el archivo `.tif`.



Luego de importar los productos georreferenciados a QGIS, les invitamos a probar varios fondos de QuickMapServices > Google (ej. Google Terrain), e investigar los siguientes aspectos:

- ¿Existe alguna relación entre la variación espacial del pH y la distribución o ubicación de los puntos de muestreo?
- ¿A qué factores se podrían atribuir los cambios en los valores de pH?

10. Conclusiones

¡Felicidades por haber completado esta práctica! Hemos recorrido todo el flujo de trabajo geoestadístico: desde el análisis exploratorio hasta la visualización de los resultados.

A lo largo de este práctico, no solo hemos aplicado los conceptos teóricos para analizar la variación espacial del pH en suelos, sino que también nos hemos familiarizado

con el método de **kriging** para predecir valores en áreas no muestreadas. Además, adquirimos mayor práctica en la exportación de los resultados a formatos GIS, lo que permite integrar el análisis en flujos de trabajo más amplios.

Las preguntas que se plantearon a lo largo del ejercicio nos invitan a reflexionar sobre la importancia de cada paso: desde la elección del modelo de variograma hasta la interpretación de los mapas de varianza. Comprender estos conceptos es crucial para evaluar la calidad de las predicciones y tomar decisiones informadas sobre futuros muestreos. El conjunto de actividades que hemos resuelto aquí nos ha preparado de manera integral para resolver el cuestionario evaluativo de esta unidad y para abordar el desafío del **trabajo práctico integrador**.

¡Mucho éxito en la última etapa!

11. Bibliografía

Azcarate P., N. Kloster, y G. Pérez Habiag. 2012. Reacción del suelo: pH. En: Manual de Fertilidad y Evaluación de Suelos. Alberto Quiroga y Alfredo Bono (editores). Ed. INTA. Anguil. pp. 19-24.

Esterlich, C., J. Ossola, L. Juan, M. Vázquez, y G. Millán. 2012. Efecto de la fertilización nitrogenada sobre el pH en dos suelos de la Pradera Pampeana. XIX Congreso Latinoamericano y XXIII Congreso Argentino de la Ciencia del Suelo, abril, Mar del Plata, Argentina.

Vázquez, M. 2007. Calcio y Magnesio del suelo. Encalado y enyesado. En: Fertilidad de suelos y fertilización de cultivos. Ed. Echeverría, H., F. García. INTA, 2da reimpression. 1ra Ed. Cap. 8:181-188. 525 p.

Vázquez, M., A. Pagani. 2015. Calcio y magnesio del suelo. Encalado y enyesado. En: Fertilidad de suelos y fertilización de cultivos. Echeverría, H., F. García (ed.). Cap. 11:317-355. Ed. INTA. Buenos Aires, Argentina.

¿Cómo citar este material?

Aguilera Sammaritano, M. & Equipo de Educación a Distancia Mario Gulich. (2022) [2025]. [Adaptación de Galetto, A.]. Unidad 3: Práctico de Variación espacial y predicción de la acidificación del suelo. Módulo 3: Análisis de datos espaciales y sus aplicaciones. Diplomatura Universitaria en Geomática Aplicada. Instituto Superior de Altos Estudios Espaciales Mario Gulich. CONAE. Universidad Nacional de Córdoba.

Los materiales del Instituto de Altos Estudios Espaciales Mario Gulich se producen de manera colaborativa e interdisciplinaria entre distintos equipos de trabajo.

Este material está bajo una licencia Creative Commons ([CC BY-NC-SA 4.0](https://creativecommons.org/licenses/by-nc-sa/4.0/))

